Cours Python : Introduction à Xarray

Pourquoi Xarray

- Xarray est une bibliothèque Python pour la manipulation de données multi-dimensionnelles.
- Inspirée par **Pandas**, elle facilite l'analyse de données N-dimensionnelles.
- Elle est idéale pour travailler avec des données météorologiques indexées selon **lat**, **lon**, **time**.
- Xarray gère différents formats de données utilisés en météorologie (**netcdf**, grib, zarr) => Permet d'avoir le même code applicatif à l''ouverture du fichier prêt.
- **Gère et propage** les métadonnées tout du long des calculs.

Ajout de bibliothèque à l'environnement existant

Pour ce TP il vous faudra installer `xarray`, `matplotlib` et `netCDF4`.

Pour cela :

- Activer l'environnement virtuel créé lors du dernier TP.
- Faire ensuite

```
pip install xarray matplotlib netCDF4
```

Ouverture d'un fichier Netcdf

```
import xarray as xr
ds = xr.open_dataset("/home/newton/ienm2021/chabotv/COURS_CS/arome_forecast_2024100900.nc")
#Affiche le contenu du fichier
print(ds)
```

Résultat de l'ouverture

```
<xarray.Dataset> Size: 69MB
Dimensions:             (latitude: 1200, longitude: 1600, time: 4)
Coordinates:
  * latitude            (latitude) float64 10kB 53.4 53.39 53.38 ... 41.42 41.41
  * longitude           (longitude) float64 13kB -8.0 -7.99 -7.98 ... 7.98 7.99
  * time                (time) datetime64[ns] 32B 2024-10-09T01:00:00 ... 2024...
    heightAboveGround   float64 8B ...
Data variables:
    altitude            (latitude, longitude) float32 8MB ...
    t2m                 (time, latitude, longitude) float32 31MB ...
    r2                  (time, latitude, longitude) float32 31MB ...
Attributes:
    GRIB_edition:            2
    GRIB_centre:             lfpw
    GRIB_centreDescription:  French Weather Service - Toulouse
    GRIB_subCentre:          0
    Conventions:             CF-1.7
    institution:             French Weather Service - Toulouse
    history:                 2024-10-10T09:28 GRIB to CDM+CF via cfgrib-0.9.1...
```

Qu'avons nous chargé ?

Un fichier contenant trois variables :

- **t2m** (temperature)
- **r2** (humidité spécifique)
- **altitude**

Ces variables possèdent des coordonnées (**time**, **latitude**, **longitude**)
Le fichier, ainsi que l'ensemble des variables et coordonnées, possède des attributs.

Ex : `history` renseigne sur la manière dont a été créer le fichier.

Dans le *vocabulaire* xarray, une variable particulière d'un *Dataset* s'appel un *DataArray*.

Exercice 1

En consultant les attributs de la variable `t2m`, retrouver en quelle unité est stockée la temperature.

Selection de données

Il y a deux manières principales de selectionner des données :

- par valeur

```
t2m_toulouse = ds["t2m"].sel(latitude=43.6,longitude=1.43,method="nearest")
```

`method=nearest` pemet de selectionner le point de grille le plus proche.

- par indice

```
t2m_by_index = ds["t2m"].isel(latitude=198,longitude=705)
```

Selection de données : par plage

On peut aussi selectionner via une liste ou des "slices"

```
t2m_area = ds["t2m"].sel(latitude=slice(44,42),longitude=slice(0,2))
```

Attention : La sélection suivante n'aurait sélectionné aucune donnée !

```
t2m_area = ds["t2m"].sel(latitude=slice(42,44),longitude=slice(0,2))
```

En effet, les latitudes sont rangées de manière décroissante dans ce fichier.

Exercice 2

1. Retrouver la position (en latitude/longitude) du point de grille situé à l'index (198,705) de l'exemple précédent.
2. Quelle est la température à 2h du matin à Paris ?
3. Combien de point de grille ont été selectionnés par la commande suivante

```
t2m_area = ds["t2m"].sel(latitude=slice(44,42),longitude=slice(0,2))
```

Calculs sur les données

On peut directement faire des calculs sur un *Dataset* ou sur un *DataArray*

```
# Moyenne temporelle pour toutes les variables du dataset
ds_temporal_mean = ds.mean(dim="time")
# Variation spatiale
ds_std = ds.std(dim=["latitude","longitude"])
```

NB On peut aussi employer directement des fonctions `numpy` sur un `DataArray`.

```
np.mean(ds["t2m"],axis=[0]) <=> ds["t2m"].mean(dim="time")
```

Exercice 3

- Quelles sont les dimensions de vos variable après la moyenne temporelle ?
- Quelle est la température moyenne sur la période sur un rectangle
  - latitude : [42, 44]
  - longitude : [0, 2]

Visualisation rapide (via matplotlib)

Attention : On peut uniquement utiliser la fonction de plot sur les **DataArray**.

```
import matplotlib.pyplot as plt
ds_temporal_mean["t2m"].plot()
plt.show()
```

Bonus : On a directement accès aux coordonnées sur le plot

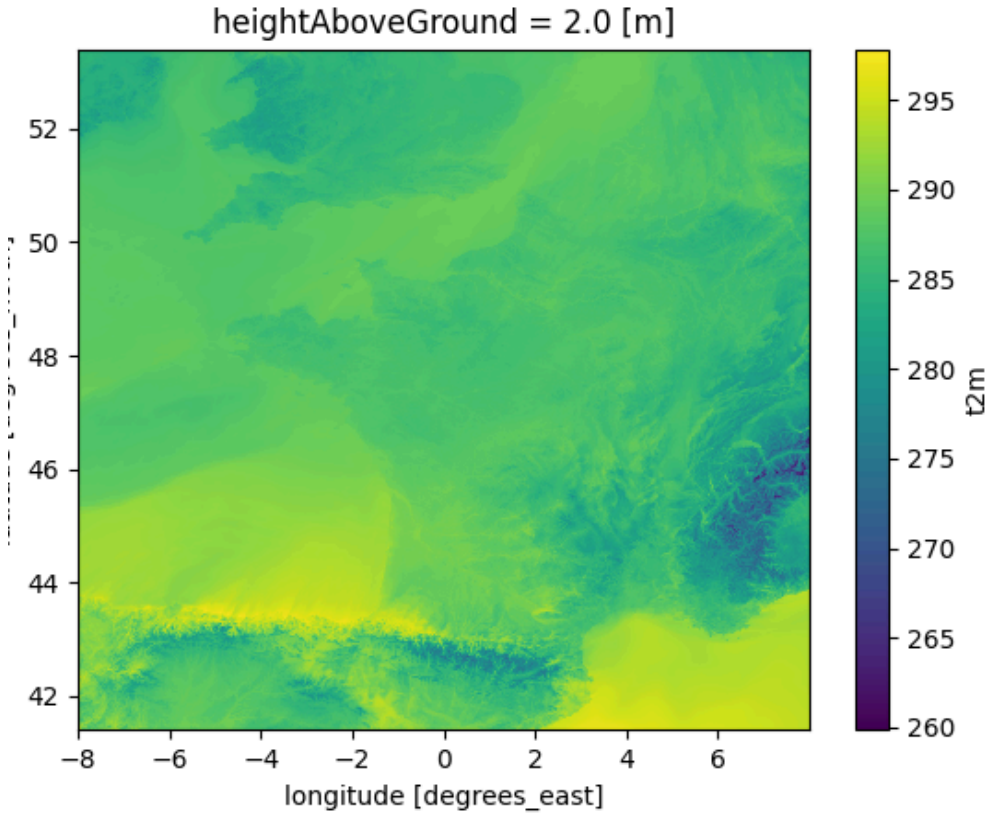

Exercice 4

- Afficher l'altitude sur un carré d'un degré de côté centré autour de Grenoble.

Solution 4 : rendu

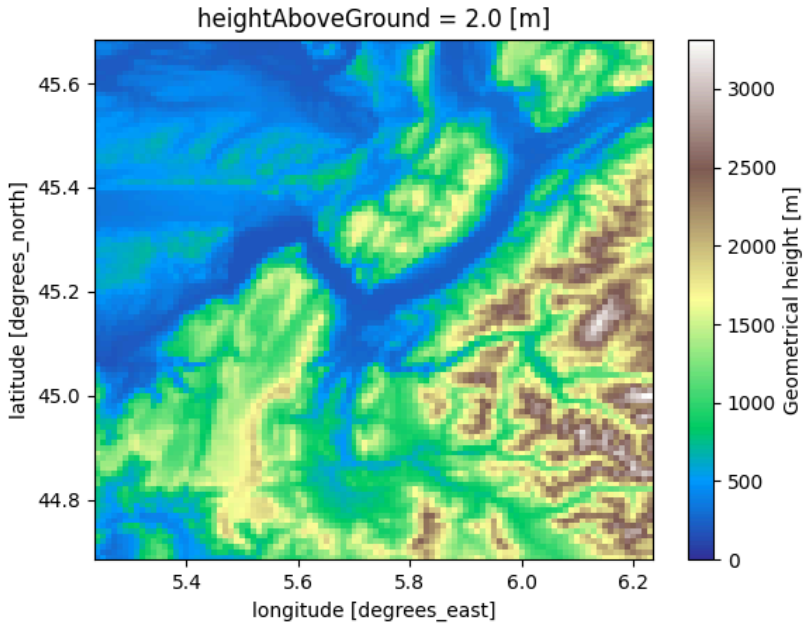

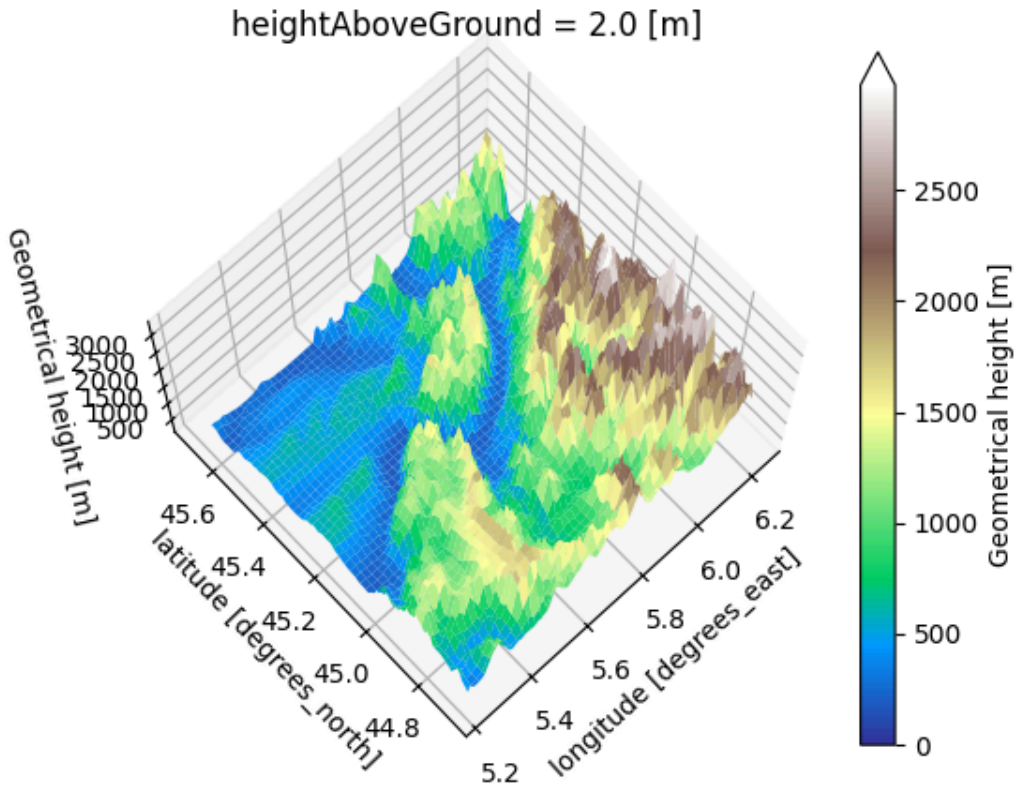

Utilisation des masques pour calculer sur des sous domaines

Avec *xarray* (et numpy) On peut aisément créer des masques et les utiliser.
Cela peut ce faire comme dans l'exemple suivant avec `where` ou par simple multiplication.

```
mask = ds["altitude"] > 1000
temperature_above_1000 = ds["t2m"].where(mask)
mean = temperature_above_1000.mean()
print(f" Temperature moyenne des points ayant une altitude supérieure à 1000 m : {str(mean)} {mean.units}"))
```

```
> Temperature moyenne des points ayant une altitude supérieure à 1000 m : 281.15 K
```

Exercice 5

Faite une fonction permettant de calculer la température moyenne d'une zone donnée pour les points situés au dessus d'une certaine altitude.

Exercices (Optionel)

1. Améliorer la fonction de l'exercice 5 de telle sorte à prendre en entrée la variable d'intérêt dans le dataset (par ex. `r2` ou `t2m`)
2. Combien y-a-t'il d'occurences de température négative (en °C) dans le dataset entier ? Quel pourcentage de cas cela représente-t-il ?
3. Calculer la moyenne glissante (sur 3h) pour la zone autour de Grenoble. (Indication : utiliser la fonctionnalité `rolling` de *xarray*)